
Bases de Datos SQL para el análisis de variantes genéticas



**Máster en Bioinformática y Ciencia de Datos
en Medicina Personalizada de Precisión y Salud**

Autores

Álvaro García Barragán
Pablo Fernández Lagos

Abril, 2026

Índice

1. Introducción	1
2. Carga de Datos	1
3. Modelo de Datos	2
3.1. Mapeo de Columnas	2
3.2. Diagramas Entidad Relación	2
3.2.1. ClinVar	2
3.2.2. Civic	3
3.2.3. Relaciones Variante-Gen	4
3.3. Estadísticas generales	5
4. Programas ETL	5
5. Consultas SQL	6
A. Mapeo de Columnas	14

1. Introducción

En este documento se describe el desarrollo de un proceso ETL (Extracción, Transformación y Carga de datos) a partir de las bases de datos de [ClinVar](#) y [CIViC](#).

El desarrollo del proyecto se llevó a cabo en un sistema operativo Unix basado en Ubuntu 24.04.3 LTS. Para la gestión de la base de datos se utilizó SQLite versión 3.45.1, mientras que los scripts de extracción y transformación fueron implementados en Python versión 3.12.3. Todo el código fuente está disponible en <https://github.com/Alvaro8gb/genomic-variants-etl> y es reproducible end2end ejecutando el programa *run.sh*.

El documento se encuentra dividido en cuatro secciones, diseñadas para garantizar la reproducibilidad del trabajo. En primer lugar, la [Sección 2](#) describe la carga de datos y los recursos empleados para la descarga de la información. A continuación, en la [Sección 3](#), se presenta el modelo de datos relacional utilizado. La [Sección 4](#) detalla los scripts ETL desarrollados para la extracción y transformación de los datos. Finalmente, la [Sección 5](#) expone las consultas realizadas y los resultados obtenidos a partir de las bases de datos generadas.

2. Carga de Datos

El flujo de trabajo comienza con la automatización de la descarga de variantes mediante el uso de un programa en Bash: *download.sh*¹.

Se utilizaron comandos estándar de la línea de comandos de Unix para la gestión de archivos y red:

- `mkdir -p`: Para la creación de directorios, asegurando que las rutas de destino existan antes de la transferencia.
- `wget -nc`: Para la descarga de archivos desde repositorios remotos. Se empleó el flag *no-clobber* para evitar descargas si ya existe el fichero.

El programa interactúa con dos repositorios:

1. **ClinVar (NCBI)**: Los archivos (sumarios de variantes, estadísticas y envíos) se obtienen de la versión de diciembre de 2025.
2. **CIViC**: La base de datos de variantes de cáncer se consulta a través de su repositorio oficial, a partir de los sumarios de variantes, evidencias clínicas y perfiles moleculares con fecha de corte de diciembre de 2025.

Después de la ejecución, los siguientes archivos son descargados y sus *hashes* generados, tal y como se muestra en [Tabla 1](#).

Cuadro 1: Ficheros Descargados

Fuente	Nombre del Fichero	Hash MD5
ClinVar	variant_summary_2025-12.txt.gz	28b6e20193a582dcf804fecf98af1c7f
	gene_specific_summary_2025-12.txt.gz	1c8da34fe64b0b9b9efd54fea2c46419
	submission_summary_2025-12.txt.gz	5299fc3c9989b511283bf45a808aea0e
CIViC	01-Dec-2025-VariantSummaries.tsv	36c5c591a5b9e60c7302373a166a6d8f
	01-Dec-2025-ClinicalEvidenceSummaries.tsv	194af87f5718002b6bd03e19b7beedfa
	01-Dec-2025-MolecularProfileSummaries.tsv	f273ec7f3f87008e2806daaa2121bc84

¹<https://github.com/Alvaro8gb/genomic-variants-etl/blob/main/scripts/download.sh>

3. Modelo de Datos

El modelo de datos SQL se ha definido a partir de un análisis manual de los datos en crudo descargados previamente.

Durante este análisis se detectaron columnas que representaban valores nulos utilizando diferentes convenciones, tales como “-”, “na” o “N/A”. Todos estos valores fueron normalizados y convertidos a valores NULL compatibles con SQL.

En aquellas columnas donde el modelo de datos no permite valores nulos, como el cromosoma y su posición genómica, se ha utilizado el valor -1 como marcador de valor nulo.

3.1. Mapeo de Columnas

El modelo de datos se ha diseñado para unificar la información proveniente de ClinVar y CIViC, utilizando columnas compartidas (con mismo nombre) que representan los mismos conceptos genómicos en ambas fuentes.

Por ejemplo la tabla `variant` de CIViC utiliza las mismas columnas genómicas que la tabla `variant` de ClinVar para la representación de coordenadas, alelos y ensamblaje, lo que permite un mapeo directo de variantes entre ambas fuentes de datos.

El mapeo entre los nombres originales de las columnas de cada fuente y los nombres de las columnas destino definidos se presenta en las tablas [Apéndice A](#).

3.2. Diagramas Entidad Relación

3.2.1. ClinVar

El modelo entidad-relación para los datos de ClinVar ([Figura 1](#)) se ha definido teniendo en cuenta las siguientes características y decisiones de diseño:

- El símbolo del gen (`gene_symbol`) se ha definido como clave primaria de la entidad `gene`, ya que presenta un mayor número de valores distintos en comparación con otros identificadores, como `gene_id`, y es el identificador más comúnmente compartido entre las fuentes de datos integradas.
- Dado que una misma variante puede aparecer en diferentes versiones del genoma, se ha introducido una clave artificial autoincremental, denominada `ventry_id`, que identifica de forma única cada entrada de variante en el modelo. Este identificador se utiliza como referencia común entre las tablas relacionadas con variantes.

La base de datos principal de variantes de Clinvar tiene las siguientes entidades.

- La entidad `gene` almacena la información génica, incluyendo el símbolo del gen y los otros identificadores (`gene_id` y `hgnc_id`).
- La entidad `variant` constituye el núcleo del modelo y representa las variantes genéticas. Contiene información sobre el gen asociado, la localización cromosómica (`chro`, `chro_start`, `chro_stop`), los alelos de referencia y alternativo (`ref_allele`, `alt_allele`) y el ensamblaje genómico (`assembly`).
- Las entidades `clinical_sig`, `review_status` y `variant_phenotypes` almacenan información complementaria asociada a las variantes. Dado que una misma variante puede presentar múltiples valores de significancia clínica, estados de revisión o fenotipos asociados, estas entidades se modelan en tablas independientes y se relacionan con la entidad `variant` mediante el identificador `ventry_id`.




Figura 1: Esquema de Variantes de Clinvar

Las estadísticas de los genes se han organizado en una única tabla, como se muestra en [Figura 2](#). En ella se ha definido un identificador incremental `gen_id_stats`, que permite asociar a cada gen los siguientes atributos: número total de envíos, número total de alelos, cantidad de envíos que reportan este gen, número de alelos reportados como patogénicos, número MIM del gen, cantidad de variantes de significado incierto y número de variantes con conflictos. Este identificador se ha creado debido a la existencia de entradas con `gen_symbol` duplicado; hay 92,493 identificadores únicos frente a 92,481 `gen_symbol` únicos.




Figura 2: Esquema de Estadísticas de Genes de Clinvar

Por último, los envíos de ClinVar se muestran en la [Figura 3](#). Para cada `submission_id` se puede obtener el gen reportado, la significancia clínica, la fecha de la última evaluación y la información fenotípica asociada. Además, se ha implementado una lógica que, a partir de la descripción del envío, extrae los identificadores de los artículos de *PubMed* (*PMID*). Como un envío puede estar asociado a varios *PMIDs*, se ha creado una tabla con una relación uno a muchos, utilizando `submission_id` como elemento de enlace.

3.2.2. Civic

Las variantes son guardadas en la tabla *variant* y dado que una *feature* de una variante comparte atributos comunes, como el nombre y el tipo, para evitar duplicidad de datos se ha creado una tabla específica para almacenar esta información (table:feature) tal y como se muestra en [Figura 4](#).




Figura 3: Esquema de *Submission* de Clinvar




Figura 4: Esquema de Variantes de CiVic

En CIViC, el fenotipo no es un atributo directo de la variante, sino que forma parte de una estructura jerárquica compleja donde una variante se integra en un Perfil Molecular. Este perfil se vincula a múltiples Ítems de Evidencia, donde el fenotipo (o enfermedad) es solo uno de los parámetros dentro de un contexto clínico específico (pronóstico, diagnóstico o predictivo).

Esto se ve reflejado en su esquema de base de datos en [Figura 5](#) y [Figura 6](#), donde cada evidencia tiene un perfil molecular y cada perfil molecular puede tener mas de un ítem de evidencia y estar relacionado con mas de una variante.

3.2.3. Relaciones Variante-Gen

Los datos de ClinVar modelan únicamente relaciones 1:1 entre variante y gen; es decir, cada variante se asocia a un único gen. Esto implica que ClinVar no contempla variantes que involucren genes de fusión. En contraste, CIViC permite un modelo más flexible (tabla *feature*), en el que una variante puede asociarse a más de un gen (1:N), incluyendo genes de fusión —como




Figura 5: Esquema de Evidencias Clínicas de CIViC




Figura 6: Esquema de Perfil Molecular de CIViC

eventos que combinan dos genes distintos— o factores moleculares.

Debido a esto se ha eliminado por redundancia la tabla `variant2gen`.

3.3. Estadísticas generales

ClinVar contiene 4,214,112 variantes (`variant_id`) y 8,364,862 entradas (`ventry_id`), asociadas a 40,294 genes distintos.

CIViC, por su parte, cuenta con 1,898 variantes, pero solo 335 genes distintos.

4. Programas ETL

Se han implementado cuatro scripts ETL para procesar datos de variantes genómicas. Cada fichero de datos descargado cuenta con un ETL específico que lo transforma en un archivo de base de datos (`.db`) listo para su análisis. Estos ETLs se puede ejecutar con el `script etls.sh`², los nombres de los programas se muestran en [Tabla 2](#).

Programa ETL	Fichero de Entrada	Fichero Base de Datos
<code>clinvar_variant_etl.py</code>	<code>variant_summary_2025-01.txt.gz</code>	<code>clinvar_variant.db</code>
<code>clinvar_gene_stats_etl.py</code>	<code>gene_specific_summary_2025-01.txt.gz</code>	<code>clinvar_gene_stats.db</code>
<code>clinvar_submission_etl.py</code>	<code>submission_summary_2025-01.txt.gz</code>	<code>clinvar_submission.db</code>
<code>civic_variant_etl.py</code>	<code>01-Dec-2025-VariantSummaries.tsv</code>	<code>civic_variant.db</code>
<code>civic_molecular_etl.py</code>	<code>01-Dec-2025-MolecularProfileSummaries.tsv</code>	<code>civic_molecular.db</code>
<code>civic_clinical_etl.py</code>	<code>01-Dec-2025-ClinicalEvidenceSummaries.tsv</code>	<code>civic_clinical.db</code>

Cuadro 2: Relación entre scripts ETL, ficheros de entrada y bases de datos de salida.

Los pipelines siguen el patrón clásico ETL:

- **Extracción:** Se cargan los ficheros de datos comprimidos (`.gz`) que tienen formato tabular, fila por fila. Se excluyen las líneas de comentarios al inicio de los ficheros y se identifica la fila que contiene los nombres de las columnas (cabeceras).
- **Transformación:**
 - **Tratamiento de nulos:** Se convierten los valores nulos a formatos estándar.
 - **Casteo de tipos:** Se convierten textos a números o a otros tipos de datos cuando es necesario.

²<https://github.com/Alvaro8gb/genomic-variants-etl/blob/main/scripts/etls.sh>

- **Aplicación de reglas:** Se realizan transformaciones específicas, como la extracción de PMIDs u otras anotaciones relevantes.
- **Carga:** Se inicializa la base de datos y se insertan los registros transformados respetando las relaciones y restricciones definidas en los esquemas SQL.

5. Consultas SQL

Las consultas a las bases de datos se han diseñado utilizando el cliente gestor [DBLeaver](#), después han sido automatizadas en un programa llamado `querie_caller.py`.

1. ¿Cuántas variantes están relacionadas con el gen P53 tomando como referencia el ensamblaje GRCh38 en ClinVar y en CIViC?

El gen P53 tiene varios sinónimos, para poder obtener todas las variantes relacionadas se consultó [Gencards](#) y Gene del [NCBI](#). El nombre principal del gen es TP53, y sus sinónimos son: P53, BCC7, LFS1, BMFS5, TRP53.

Tras ejecutar la consulta, se comprobó que todas las variantes estaban finalmente etiquetadas únicamente con el nombre principal TP53 en ClinVar. Sin embargo, en CIViC no existen referencias a TP53 en GRCh38.

```
SELECT
    COUNT(DISTINCT variant_id)
FROM variant
WHERE
    gene_symbol IN ('TP53',
                   'P53', 'BCC7', 'LFS1',
                   'BMFS5', 'TRP53') -- https://www.ncbi.nlm.nih.gov/gene/7157
    AND assembly = 'GRCh38';
```

Resultado ClinVar: 3,758 Resultado Civic: 0

2. ¿Qué cambio del tipo “single nucleotide variant” es más frecuente, el de una Guanina por una Adenina, o el de una Guanina por una Timina? Usad las anotaciones basadas en el ensamblaje GRCh37 para cuantificar y proporcionar los números totales, tanto para ClinVar como para CIViC.

```
SELECT
    ref_allele,
    alt_allele,
    COUNT(variant_id) AS n_variants
FROM variant
WHERE
    assembly = 'GRCh37' AND
    -- AND variant_type = 'single nucleotide variant'
    ref_allele = 'G'
    AND (alt_allele = 'A' OR alt_allele = 'T')
GROUP BY ref_allele, alt_allele
ORDER BY n_variants DESC;
```

Resultado combinado:

Alelo ref	Alelo alt	# Variantes ClinVar	# Variantes CIViC
G	A	798,290	105
G	T	232,695	54

3. ¿Cuáles son los tres genes de ClinVar con un mayor número de inserciones, deleciones o indels? Usa el ensamblaje GRCh37 para cuantificar y proporcionar los números totales.

```
SELECT
    gene_symbol,
    COUNT(DISTINCT(variant_id)) as n_variants
FROM variant
WHERE
    assembly = 'GRCh37' AND
    variant_type IN ('Indel', 'Insertion', 'Deletion')
GROUP BY gene_symbol
ORDER BY n_variants DESC
LIMIT 3;
```

Resultado:

Gen	#Variantes
BRCA2	3,788
BRCA1	3,034
NF1	2,954

4. ¿Cuál es la delección más común en el cáncer hereditario de mama en CIViC? ¿Y en ClinVar?

Debido a que se utilizan diferentes vocabularios para codificar enfermedades en CIViC y en ClinVar, esta consulta no se ha podido compartir entre ambas.

Clinvar

Para obtener el cáncer hereditario de mama tenemos que buscar que variantes coinciden con el fenotipo. Primero se buscó en la base de datos todas las ontologías en las que se etiquetan los fenotipos utilizando la siguiente consulta.

```
SELECT DISTINCT phen_ns
FROM variant_phenotypes
ORDER BY phen_ns ASC;
```

Resultado: MONDO, MedGen, OMIM, Orphanet, MeSH, Human Phenotype Ontology, EFO, Gene

Una vez obtenidas, se buscaron los siguientes términos sinónimos: *hereditary breast cancer*, *hereditary breast carcinoma* y *familial cancer of breast* en todas las ontologías y se encontraron los siguientes códigos que se muestran en [Tabla 3](#).

Ontología	Fenotipo	Código
MONDO	<i>hereditary breast carcinoma</i>	0016419
ORPHANET	<i>hereditary breast cancer</i>	227535
OMIM	<i>BREAST CANCER</i>	114480
MedGen	<i>Familial cancer of breast</i>	87542

Cuadro 3: Códigos para términos relacionados con cáncer de mama hereditario.

```

SELECT
    v.ref_allele,
    v.alt_allele,
    COUNT(DISTINCT(variant_id)) AS n_variants
FROM variant v
JOIN variant_phenotypes vp ON v.ventry_id = vp.ventry_id
WHERE
    v.variant_type = 'Deletion'
    AND (
        (vp.phen_ns = 'Orphanet' AND vp.phen_id = '227535')
        OR (vp.phen_ns = 'MONDO' AND vp.phen_id = '0016419')
        OR (vp.phen_ns = 'OMIM' AND vp.phen_id = '114480')
        OR (vp.phen_ns = 'MedGen' AND vp.phen_id = '87542')
    )
GROUP BY v.ref_allele, v.alt_allele
ORDER BY n_variants DESC
LIMIT 1;

```

Resultado:

Alelo Ref	Alelo Alt	#Variantes
CT	C	356

CiVic

Para la realización de esta consulta primero se consulto en la tabla *disease* cuantos tipos de cáncer de mama existen. Donde se vio que existían 5 tipos y no estaba en ninguno presente el complemento de cáncer hereditario.

```

SELECT *
FROM disease
WHERE disease_name LIKE "%breast cancer%";

```

Resultado:

doid	disease_name
1612	Breast Cancer
60075	Estrogen-receptor Positive Breast Cancer
60079	Her2-receptor Positive Breast Cancer
60080	Her2-receptor Negative Breast Cancer
60081	Triple-receptor Negative Breast Cancer

Por esta razón se tuvo que buscar en la tabla *evidence_type* los tipos de evidencia, donde se encontro que el tipo de evidencia *Predisposing* hace referencia al cáncer hereditario.

Más tarde se junto esta información con las variantes y aparecieron 7 variantes de cáncer de mama hereditario.

```
SELECT DISTINCT evidence_type
FROM clinical_evidence;
```

Resultado: Diagnostic, Predictive Prognostic, Predisposing, Oncogenic, Functional

```
SELECT
    pv.variant_id, d.disease_name
FROM clinical_evidence ce
JOIN disease d
    ON d.doid = ce.doid
JOIN profile_variant pv
    ON pv.molecular_profile_id = ce.molecular_profile_id
WHERE
    d.disease_name LIKE "%breast cancer%" AND
    ce.evidence_type = "Predisposing";
```

Resultado:

Variant ID	Disease Name
471	Breast Cancer
477	Breast Cancer
4,968	Breast Cancer
661	Breast Cancer
708	Breast Cancer
709	Breast Cancer
711	Breast Cancer

Finalmente los alelos de referencia y alterados fueron buscados de estas variantes, y ninguna de ellas era de tipo delección.

```
SELECT
    v.ref_allele,
    v.alt_allele,
    v.variant_types,
    COUNT(DISTINCT(v.variant_id)) AS n_variants
FROM (
    SELECT
        DISTINCT pv.variant_id
        FROM clinical_evidence ce
        JOIN disease d
            ON d.doid = ce.doid
        JOIN profile_variant pv
            ON pv.molecular_profile_id = ce.molecular_profile_id
        WHERE
            d.disease_name LIKE "%breast cancer%" AND
            ce.evidence_type = "Predisposing"
    ) v_c
JOIN variant v ON v.variant_id = v_c.variant_id
GROUP BY v.ref_allele, v.alt_allele, v.variant_types
ORDER BY n_variants DESC
```

Resultado:

Alelo Ref	Alelo Alt	Tipo de Variante	#Variantes
-	-	-	2
-	-	feature_truncation	1
-	-	gene_silenced_by_DNA_methylation	1
-	GA	frameshift_truncation	1
C	A	missense_variant	1
G	A	stop_gained	1

5. Ver el identificador de gen y las coordenadas de las variantes de ClinVar del ensamblaje GRCh38 relacionadas con el fenotipo del “Acute infantile liver failure due to synthesis defect of mtDNA-encoded proteins”.

```
SELECT
    variant_id,
    gene_symbol,
    chro,
    chro_start,
    chro_stop
FROM variant
WHERE
    assembly = 'GRCh38' AND
    phenotype_list LIKE '%Acute infantile liver
    failure due to synthesis defect of mtDNA-encoded proteins%';
```

Resultado: (5/223)

variant_id	gene_symbol	chro	chro_start	chro_stop
1290	TRMU	22	46,335,792	46,335,792
1291	TRMU	22	46,337,925	46,337,925
1293	TRMU	22	46,353,809	46,353,809
1294	TRMU	22	46,335,766	46,335,766
30819	TRMU	22	46,353,829	46,353,829

6. Para aquellas variantes de ClinVar con significancia clínica “Pathogenic” o “Likely pathogenic”, recuperar las coordenadas, el alelo de referencia y el alelo alterado para la hemoglobina (HBB) en el ensamblaje GRCh37.

En la tabla *clinical_sig* existen varios valores de *significance* para el mismo *variant_id*, dado que hay publicaciones que lo marcan como “Likely pathogenic” y “Pathogenic”. Esto se puede deber a que recientes publicaciones confirman la patogenicidad de una variante. Para nuestro resultado hemos decidido dejar ambas entradas.

```
SELECT
    v.variant_id,
    c.significance,
    v.chro,
    v.chro_start,
    v.chro_stop
FROM variant v
JOIN clinical_sig c ON v.ventry_id = c.ventry_id
WHERE
    c.significance IN ('Pathogenic', 'Likely pathogenic') AND
    v.assembly = 'GRCh37' AND
    v.gene_symbol = 'HBB';
```

Resultado (6/421):

variant_id	significance	chro	chro_start	chro_stop
15090	Pathogenic	11	5,246,841	5,246,841
15090	Likely pathogenic	11	5,246,841	5,246,841
15096	Pathogenic	11	5,246,837	5,246,837
15112	Pathogenic	11	5,246,836	5,246,836
15122	Pathogenic	11	5,247,865	5,247,865
15126	Pathogenic	11	5,248,233	5,248,233

7. Calcular el número de variantes del ensamblaje GRCh37 en el cromosoma 13 entre las coordenadas 10,000,000 y 20,000,000.

```
SELECT
    COUNT(DISTINCT(variant_id))
FROM variant
WHERE
    assembly = 'GRCh37' AND
    chro = 13 AND
    chro_start >= 10000000 AND
    chro_stop <= 20000000;
```

Resultado Clinvar: 70 variantes Resultado CiVIC: 0 variantes

8. Calcular el número de variantes de ClinVar para los cuáles se haya provisto entradas de significancia clínica que no sean inciertas ("Uncertain significance"), del ensamblaje GRCh38, en aquellas variantes relacionadas con BRCA2.

```
SELECT
    COUNT(DISTINCT(v.variant_id))
FROM variant v
JOIN clinical_sig c ON v.ventry_id = c.ventry_id
WHERE
    c.significance != 'Uncertain significance' AND
    v.assembly = 'GRCh38' AND
    v.gene_symbol = 'BRCA2';
```

Resultado: 16,733 variantes

9. Obtener el listado de PubMed IDs de ClinVar relacionados con variantes GRCh38 asociadas a glioblastoma.

Para realizar esta consulta se utilizó una consulta con subconsultas. En primer lugar, se buscaron las variantes relacionadas con glioblastoma y, posteriormente, a partir de estas variantes, se identificaron sus artículos científicos asociados mediante el *PMID*.

Para aumentar la precisión, en lugar de realizar una búsqueda por texto libre, se emplearon ontologías de fenotipo con el fin de identificar el código correspondiente a glioblastoma.

Los fenotipos extraídos son los siguientes:

Como se muestra en los resultados, el uso de códigos produce un menor número de artículos que la búsqueda por texto libre (58 frente a 110).

Base de datos	Fenotipo	Identificador
ORPHANET	<i>Glioblastoma</i>	360
MONDO	<i>glioblastoma</i>	0018177
OMIM	<i>GLIOMA SUSCEPTIBILITY 1; GLM1</i>	137800
MedGen	<i>Glioblastoma</i>	42228
MeSH	<i>Glioblastoma</i>	D005909

Cuadro 4: Fenotipos asociados a glioblastoma en distintas ontologías.

```

SELECT
    DISTINCT(sp.pmid)
FROM (
    SELECT DISTINCT(variant_id)
    FROM variant
    WHERE
        assembly = 'GRCh38' AND
        phenotype_list LIKE '%glioblastoma%'
) v
JOIN submission s ON v.variant_id = s.variant_id
JOIN submission_pmid sp ON s.submission_id = sp.submission_id;

```

Resultado (5/110) : 11370630, 27666373, 29979965, 32000721, 24122735

```

SELECT
    DISTINCT(sp.pmid)
FROM (
    SELECT DISTINCT(v.variant_id)
    FROM variant_phenotypes vp
    JOIN variant v ON v.ventry_id = vp.ventry_id
    WHERE
        v.assembly = 'GRCh38'
        AND (
            (vp.phen_ns = 'Orphanet' AND vp.phen_id = '360')
            OR (vp.phen_ns = 'MONDO' AND vp.phen_id = '0018177')
            OR (vp.phen_ns = 'OMIM' AND vp.phen_id = '137800')
            OR (vp.phen_ns = 'MedGen' AND vp.phen_id = '42228')
            OR (vp.phen_ns = 'MeSH' AND vp.phen_id = 'D005909')
        )
) v
JOIN subs.submission s ON v.variant_id = s.variant_id
JOIN subs.submission_pmid sp ON s.submission_id = sp.submission_id;

```

Resultado (5/58) : 18992148, 16825431, 9667259, 26681312, 34008015

10. Obtener el número de variantes del cromosoma 1 y calcular la frecuencia de mutaciones para GRCh37 y GRCh38. ¿Es esta frecuencia mayor que la del cromosoma 22? ¿Y si lo comparamos con el cromosoma X?

Para la realización de la consulta, dado que era necesario calcular las frecuencias, se utilizó un programa en Python que calcula la frecuencia de las variantes en cada cromosoma dado los tamaños cromosómicos en cada versión del genoma.

La frecuencia de mutaciones se define como:

$$\text{Frecuencia} = \frac{\text{Número de variantes}}{\text{Tamaño del cromosoma (bp)}}$$

La consulta de base de datos utiliza para contar el número de variantes por cromosoma es la siguiente:

```
SELECT
    assembly,
    chro,
    COUNT(DISTINCT(variant_id)) AS n_variants
FROM variant
WHERE chro IN ('1', '22', 'X')
    AND (assembly = 'GRCh37' OR assembly = 'GRCh38')
GROUP BY assembly, chro;
```

Después de ejecutar esta consulta, el programa calcula las frecuencias alélicas y crea una tabla tal y como se muestra en [Tabla 5](#).

Cromosoma	GRCh37		GRCh38	
	Variantes	Frecuencia	Variantes	Frecuencia
ClinVar				
1	376,941	0.0015	373,143	0.0014
22	91,898	0.0017	671,66	0.0013
X	186,235	0.0011	181,254	0.0011
CIViC				
1	58	2.3269e-07	1	4.0167e-09
22	14	2.7288e-07	-	-
X	22	1.4168e-07	-	-

Cuadro 5: Variantes y frecuencias por cromosoma

A. Mapeo de Columnas

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: gene</i>		
gene_symbol	GeneSymbol	TEXT
gene_id	GeneID	INTEGER
hgnc_id	HGNC_ID	TEXT
<i>Table: variant</i>		
ventry_id	Auto-increment	INTEGER
allele_id	AlleleID	INTEGER
variant_id	VariationID	INTEGER
variant_type	Type	TEXT
hgvs_id	Name	TEXT
gene_symbol	GeneSymbol	TEXT
dbSNP_id	RS# (dbSNP)	INTEGER
phenotype_list	PhenotypeList	TEXT
assembly	Assembly	TEXT
chro	Chromosome	TEXT
chro_start	Start	INTEGER
chro_stop	Stop	INTEGER
ref_allele	ReferenceAllele[VCF]	TEXT
alt_allele	AlternateAllele[VCF]	TEXT
cytogenetic	Cytogenetic	TEXT
<i>Tabla: gene2variant</i>		
ventry_id	variant.ventry_id	INTEGER
gene_symbol	GeneSymbol	TEXT
<i>Table: clinical_sig</i>		
ventry_id	variant.ventry_id	INTEGER
significance	ClinicalSignificance	TEXT
<i>Tabla: review_status</i>		
ventry_id	variant.ventry_id	INTEGER
status	ReviewStatus	TEXT
<i>Tabla: variant_phenotypes</i>		
ventry_id	variant.ventry_id	INTEGER
phen_group_id	PhenotypeIDS	INTEGER
phen_ns	PhenotypeIDS	TEXT
phen_id	PhenotypeIDS	TEXT

Cuadro 6: Mapeo de columnas de variantes de Clinvar

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: gene_stats</i>		
gene_symbol	Symbol	TEXT
gene_id	GeneID	INTEGER
total_submissions	Total_submissions	INTEGER
total_alleles	Total_alleles	INTEGER
submissions_reporting_this_gene	Submissions_reporting_this_gene	INTEGER
alleles_reported_pathogenic	Alleles_reported_Pathogenic_Likely_pathogenic	INTEGER
gene_mim_number	Gene_MIM_number	INTEGER
number_uncertain	Number_uncertain	INTEGER
number_with_conflicts	Number_with_conflicts	INTEGER

Cuadro 7: Mapeo de columnas de las estadísticas de genes de Clinvar

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: submission</i>		
submission_id	Auto-increment	INTEGER
variant_id	VariationID	INTEGER
clinical_significance	ClinicalSignificance	TEXT
date_last_evaluated	DateLastEvaluated	DATE
description	Description	TEXT
submitted_phenotype_info	SubmittedPhenotypeInfo	TEXT
reported_phenotype_info	ReportedPhenotypeInfo	TEXT
review_status	ReviewStatus	TEXT
collection_method	CollectionMethod	TEXT
origin_counts	OriginCounts	TEXT
submitter	Submitter	TEXT
scv	SCV	TEXT
submitted_gene_symbol	SubmittedGeneSymbol	TEXT
explanation_of_interpretation	ExplanationOfInterpretation	TEXT
somatic_clinical_impact	SomaticClinicalImpact	TEXT
oncogenicity	Oncogenicity	TEXT
<i>Tabla: variant_pmids</i>		
submission_id	submission.submission_id	INTEGER
pmid	Description	INTEGER

Cuadro 8: Mapeo de columnas de los envíos de Clinvar

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: feature</i>		
feature_id	feature_id	INTEGER
feature_name	feature_name	TEXT
feature_type	feature_type	TEXT
<i>Tabla: variant</i>		
variant_id	variant_id	INTEGER
caid	allele_registry_id	TEXT
variant_name	variant	TEXT
variant_aliases	variant_aliases	TEXT
variant_groups	variant_groups	TEXT
variant_types	variant_types	TEXT
feature_id	-	INTEGER
gene_symbol	gene	TEXT
entrez_id	entrez_id	INTEGER
chro	chromosome	TEXT
chro_start	start	INTEGER
chro_stop	stop	INTEGER
ref_allele	reference_bases	TEXT
alt_allele	variant_bases	TEXT
ensembl_version	ensembl_version	INTEGER
assembly	reference_build	TEXT

Cuadro 9: Mapeo de columnas de las variantes de Civic

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: feature</i>		
feature_id	feature_id	INTEGER
feature_name	feature_name	TEXT
feature_type	feature_type	TEXT
<i>Tabla: variant</i>		
variant_id	variant_id	INTEGER
caid	allele_registry_id	TEXT
variant_name	variant	TEXT
variant_aliases	variant_aliases	TEXT
variant_groups	variant_groups	TEXT
variant_types	variant_types	TEXT
feature_id	-	INTEGER
gene_symbol	gene	TEXT
entrez_id	entrez_id	INTEGER
chro	chromosome	TEXT
chro_start	start	INTEGER
chro_stop	stop	INTEGER
ref_allele	reference_bases	TEXT
alt_allele	variant_bases	TEXT
ensembl_version	ensembl_version	INTEGER
assembly	reference_build	TEXT

Cuadro 10: Mapeo de columnas de las variantes de Civic

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: disease</i>		
doid	doid	INTEGER
disease_name	disease_name	TEXT
<i>Tabla: citation</i>		
citation_id	citation_id	TEXT
source_type	source_type	TEXT
citation	citation	TEXT
<i>Tabla: clinical_evidence</i>		
evidence_id	evidence_id	INTEGER
molecular_profile_id	molecular_profile_id	INTEGER
doid	disease.doid	INTEGER
phenotypes	phenotypes	TEXT
therapies	therapies	TEXT
therapy_interaction_type	therapy_interaction_type	TEXT
evidence_type	evidence_type	TEXT
evidence_direction	evidence_direction	TEXT
evidence_level	evidence_level	TEXT
significance	significance	TEXT
evidence_statement	evidence_statement	TEXT
citation_id	citation.citation_id	TEXT
nct_ids	nct_ids	TEXT
rating	rating	INTEGER
evidence_status	evidence_status	TEXT
variant_origin	variant_origin	TEXT

Cuadro 11: Mapeo de columnas de enfermedades, citas y evidencias de CiVic

Columna Objetivo	Columna Fuente	Tipo de Dato
<i>Tabla: molecular_profile</i>		
molecular_profile_id	molecular_profile_id	INTEGER
molecular_profile_name	name	TEXT
summary	summary	TEXT
evidence_score	evidence_score	REAL
<i>Tabla: profile_evidence</i>		
molecular_profile_id	molecular_profile.molecular_profile_id	INTEGER
evidence_item_id	evidence_item_ids	INTEGER
<i>Tabla: profile_variant</i>		
molecular_profile_id	molecular_profile.molecular_profile_id	INTEGER
variant_id	variant_ids	INTEGER

Cuadro 12: Mapeo de columnas de perfiles moleculares de CiVic